Trabajo Práctico 1 Ciencia de Datos

Grupo 14

Informe final - 12 de octubre de 2026

Integrantes
Calandria, Alén Santiago - 112103
Szinvelski, Sol Yohara - 112985
Garay Alvarado, Gustavo Alfredo - intercambio-02
Sosa, Matias - 113352
Fontanals Layos, Oriol - intercambio-03

Resumen

Se integraron siete tablas de Rebrickable para estudiar perfiles de sets LEGO; se compararon dos regresores para precios de Airbnb en Toronto; y se consolidó la comparación de cinco clasificadores de cancelaciones hoteleras. Los notebooks contienen código ejecutado, decisiones metodológicas, tablas y figuras; los modelos y datos utilizados están incluidos.

Ejercicio	Resultado principal	Advertencia
LEGO	11.158 sets; k=4; Silhouette 0,353	Grupos solapados; alcance restringido a 2000-2025 y sets de 20+ piezas.
Airbnb	RF: MAE 77,15 CAD; RMSE 254,69 CAD	Precios extremos y anfitriones compartidos entre train y test.
Hoteles	Mejor F1 macro local: Voting	Validación histórica reutilizada; no equivale al score Kaggle.

EJ1. Dataset y preparación

Fuentes y unidad de análisis

Rebrickable: sets y themes describen el catálogo; inventories e inventory_parts relacionan sets con piezas; parts, colors y part_categories aportan identidad, transparencia y categorías técnicas.

La unidad final es un set: 11.158 registros y 19 columnas analíticas antes de agregar cluster. Se eligió la última versión de inventario por set; se excluyeron repuestos, cantidades no positivas y códigos de color inválidos. Los joins verifican cardinalidad para no multiplicar registros y las piezas se agregan antes de unir con sets.

Etapa	Cantidad
Sets de origen	28492
Elegibles: 2000-2025 y 20+ piezas declaradas	11186
Sin inventario válido	28
Sets analíticos	11158
Filas de inventario descartadas por calidad	2
Diferencias entre cantidad declarada y agregada	5535

Las diferencias de cantidad no se corrigen inventando piezas: inventarios, minifiguras y componentes pueden tener distinta cobertura. Se usa la cantidad observada en el inventario para comparar composición. No hubo faltantes en las claves de categorías/colores tras los joins válidos.

Variables e hipótesis

Año y tema raíz son descriptivos; cantidad de piezas, colores y categorías son conteos. Se generaron diversidad relativa (tipos de pieza/cantidad), proporción transparente y proporción Technic. Hipótesis: tamaño y composición varían entre temas; más piezas no implica proporcionalmente más colores; composición técnica puede asociarse con repetición.

Se detectaron extremos por IQR, pero se conservaron sets grandes reales. Para clustering se transformaron cantidad y colores con log(1+x) y luego se estandarizaron las cinco variables. No se incluyeron año ni tema: se busca agrupar por composición, y luego interpretar con metadatos.

EJ1. Preguntas de investigación

1. ¿Cómo varía el tamaño entre años y temas?

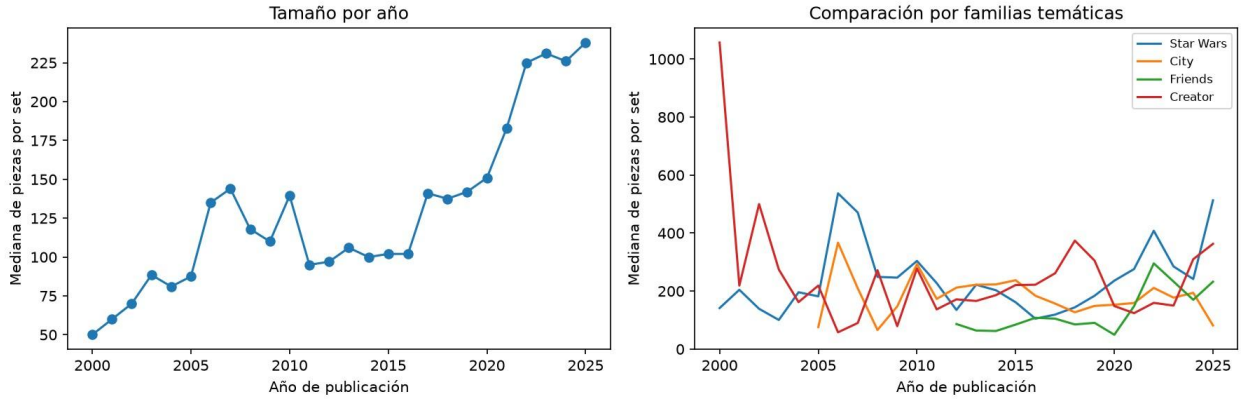


Figura 1. Medianas por año y familias temáticas; el tamaño no crece de igual manera en todos los temas.

La mediana de piezas es mayor al final del período que al principio, pero las trayectorias temáticas difieren. Es una comparación de catálogo, no seguimiento de los mismos productos ni prueba de una causa temporal.

2. ¿Más piezas implican más colores?

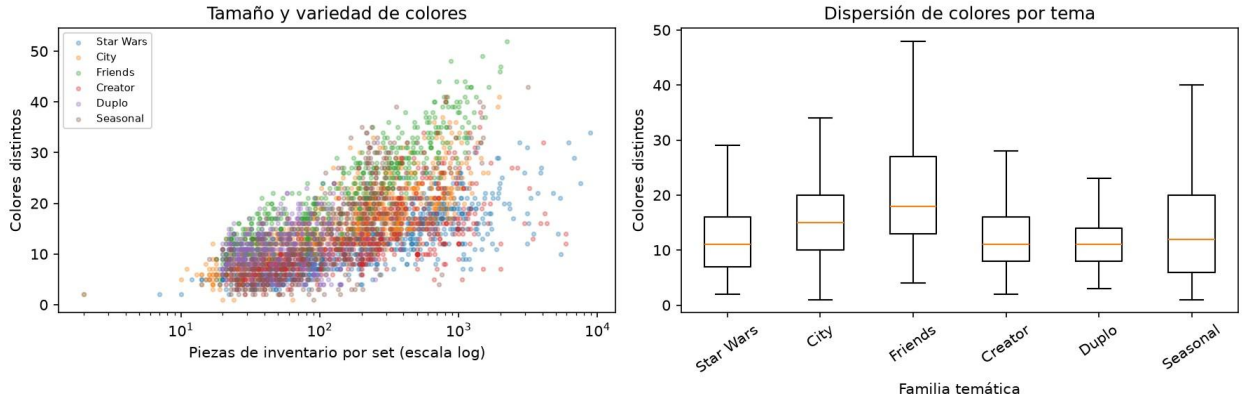


Figura 2. Cantidad y diversidad de colores, diferenciadas por tema.

La correlación de Spearman es 0,717: asociación positiva importante, con dispersión. Dos sets de tamaño semejante pueden usar distintas paletas. La relación no implica proporcionalidad ni causalidad.

EJ1. Composición y agrupamiento

3. ¿Los sets técnicos repiten más tipos de piezas?

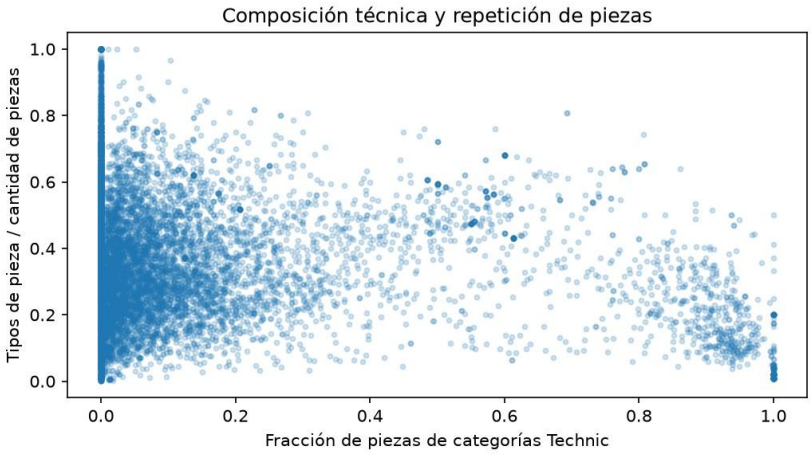


Figura 3. Fracción de piezas Technic y diversidad relativa de tipos de pieza.

Spearman = -0,183: asociación negativa débil. Los sets más técnicos tienden a menor diversidad relativa, pero hay excepciones y el tamaño puede confundir esa asociación. No alcanza para afirmar que lo técnico cause repetición.

Tendencia al agrupamiento y elección de k

Hopkins, calculado sobre vectores únicos y comparado contra puntos uniformes del espacio estandarizado, varió entre 0,926 y 0,933 en diez semillas. Sugiere estructura no uniforme, pero asimetría y dependencias también elevan el índice: no demuestra grupos naturales.

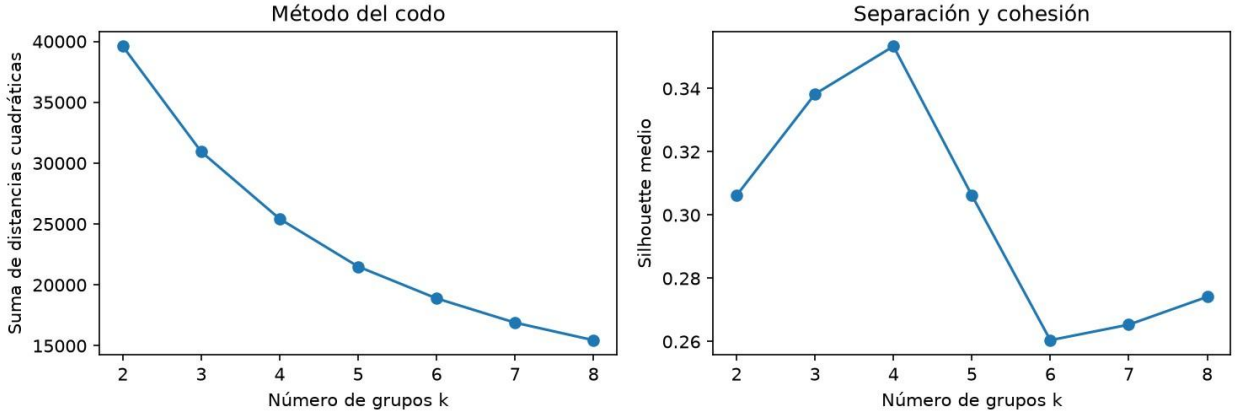


Figura 4. Comparación de k=2 a 8; Silhouette se calculó sobre una muestra fija de 3.000 sets.

Se eligió k=4 por el mayor Silhouette (0,353). La estabilidad entre semillas, medida con ARI, fue 0,997; indica consistencia de esta solución, no validez universal.

EJ1. Perfiles y conclusiones

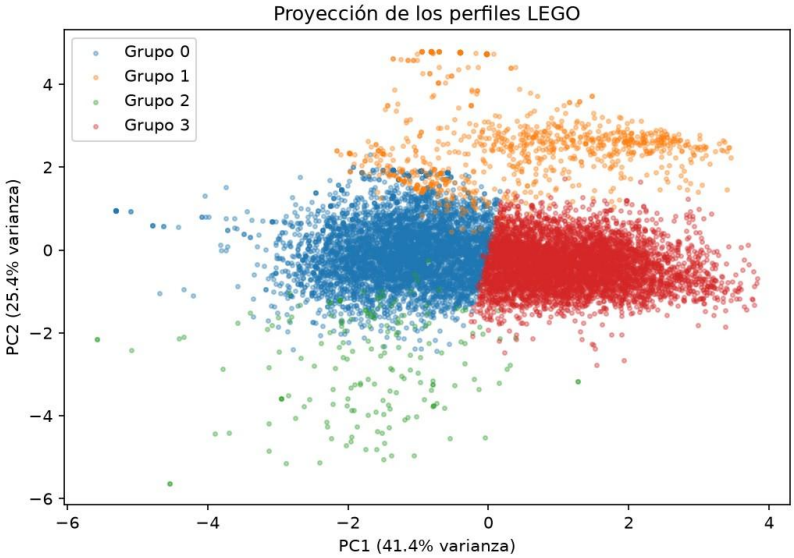


Figura 5. Proyección PCA solo para visualizar; K-Means se ajustó sobre las cinco variables estandarizadas.

Perfil descriptivo	Sets	Piezas med.	Colores med.	Rasgo distintivo
0: pequeños	5004	47	8	Diversidad relativa mediana 0,50
1: técnicos	930	140	9	81,2% de piezas Technic, promedio
2: transparentes	179	48	8	56,9% transparentes, promedio
3: grandes	5045	356	18	Mayor tamaño y paleta de colores

Los nombres son interpretaciones posteriores, no etiquetas originales. La proyección conserva aproximadamente el 66,8% de la varianza: el solapamiento visual no equivale a distancias completas. Silhouette moderado confirma que las fronteras no son perfectas.

Aplicaciones y trabajo futuro

Los perfiles pueden apoyar exploración del catálogo o comparación de sets con composición similar. No predicen calidad, dificultad ni ventas. Conviene estudiar sensibilidad al corte de 20 piezas, incluir otras épocas y revisar la cobertura de inventarios antes de generalizar. La diversidad de colores y la proporción técnica complementan al tamaño; un único conteo no resume un set.

EJ2. Airbnb: dataset y modelos

Ciudad: Toronto, asignada al grupo 14 y confirmada por el equipo. Fuente: Detailed Listings de Inside Airbnb, captura 16/09/2026. El origen contiene 22.050 anuncios y 90 columnas. Se excluyeron 5.290 sin precio positivo disponible: quedaron 16.760, divididos antes del EDA en 13.408 para train y 3.352 para test (80/20, semilla 42).

El objetivo es precio publicado por noche en CAD, no ingresos realizados. Las cotizaciones incluyen estancias y descuentos heterogéneos. Se verificó la moneda en los datos de cotización, pero se excluyeron todas las price_quote_* y estimaciones de ingresos para evitar introducir el objetivo entre predictores.

Preparación

Variables: capacidad, dormitorios, camas, baños extraídos del texto, ubicación, cantidad de amenities, reseñas, puntuación, tipo de habitación/propiedad, barrio, superhost y baño compartido. Se aplicó log(1+x) a noches mínimas y cantidad de reseñas. host_since, host_response_rate e instant_bookable están totalmente vacías: sus variables derivadas no aportaron información y el imputador las descartó.

Imputación por mediana y categoría “Sin dato”, One-Hot con categorías infrecuentes agrupadas, referencia por categoría y StandardScaler se aprenden dentro de cada fold. Se conservaron 547 precios por encima de 648,15 CAD (umbral IQR de train), para no eliminar casos difíciles del test.

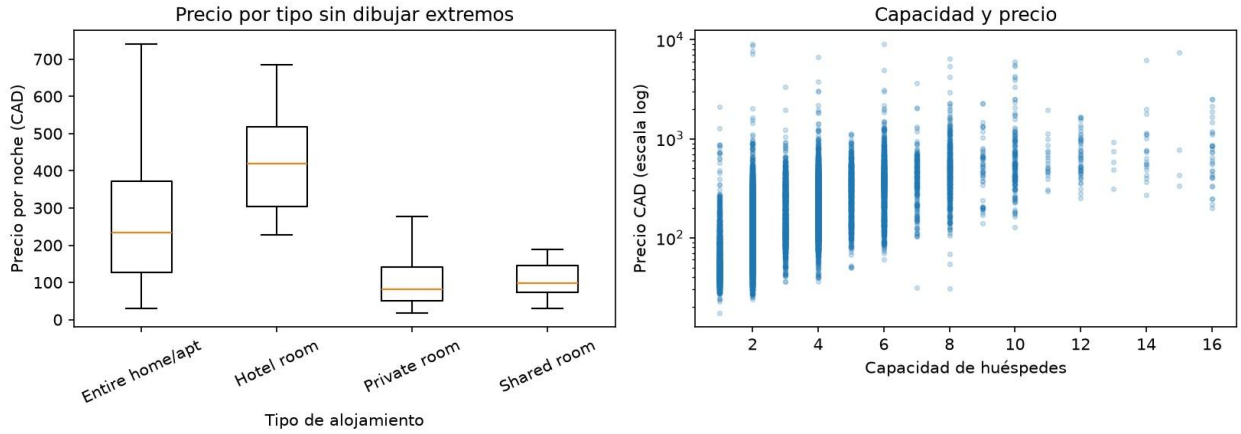


Figura 6. El precio cambia por tipo y capacidad, con gran dispersión; no se retiraron extremos del entrenamiento.

Modelos entrenados

Regresión lineal múltiple: suma ponderada de variables transformadas. RF: promedio de 250 árboles, capaz de aprender no linealidades e interacciones. Se probaron 8 configuraciones de profundidad, hoja mínima y max_features mediante 3-fold CV en train; se seleccionó por RMSE. El umbral inferior de predicción cero se fijó de antemano para ambos.

EJ2. Resultados e interpretación

Modelo / conjunto	MSE (CAD²)	RMSE (CAD)	MAE (CAD)	R^2
Regresion lineal / train	72194,9	268,69	97,26	0,314
Regresion lineal / test	68277,1	261,30	94,84	0,335
Random Forest / train	47726,3	218,46	60,27	0,547
Random Forest / test	64866,7	254,69	77,15	0,368

RF seleccionado: profundidad sin límite, mínimo 5 observaciones por hoja y 70% de variables por split; RMSE CV = 259,42 CAD. Su MAE de test mejora 17,68 CAD frente a lineal, pero el RMSE sigue alto por errores grandes. La brecha RF train/test (218,46 vs 254,69 CAD de RMSE) evidencia sobreajuste; el R^2 de 0,368 deja gran variación sin explicar.

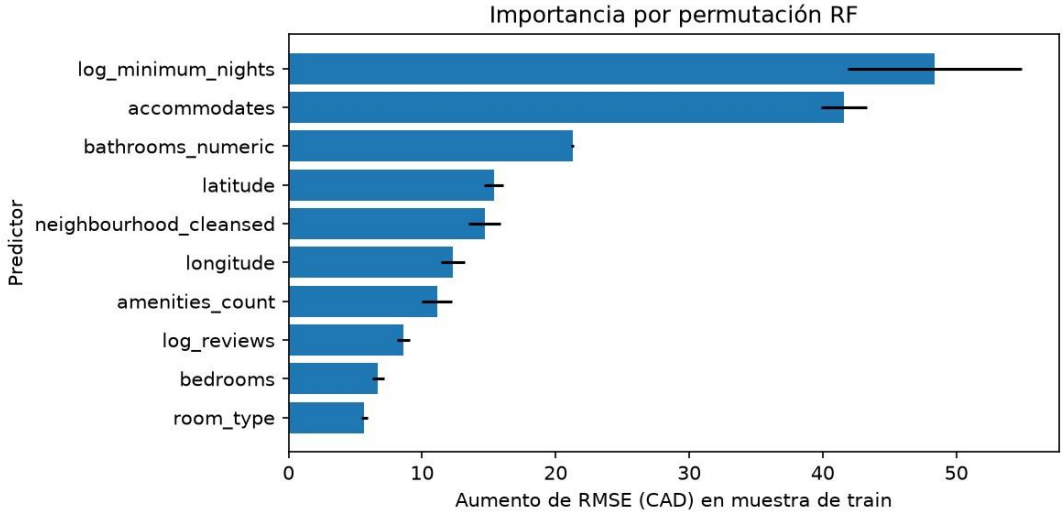


Figura 7. Importancia por permutación en una muestra de train; no constituye evaluación independiente ni efecto causal.

Noches mínimas, capacidad y baños son las principales dependencias predictivas del RF en esta medición. La ubicación también aporta. En lineal, los coeficientes numéricos corresponden a una desviación estándar; las dummies se comparan con su categoría de referencia. Los mayores coeficientes de propiedades/barrios pueden ser inestables por correlación y escasez de casos; no justifican un precio causal.

Elección y límites

Entre estas dos alternativas elegiríamos RF por menor RMSE y MAE de test. No sería suficiente para fijar precios automáticamente: el 43,65% de anuncios de test comparte anfitrión con train. Falta evaluar anfitriones/períodos nuevos, errores por segmento y sensibilidad a cotizaciones mensuales. La elección con este test tampoco reemplaza una evaluación externa posterior.

EJ3. Datos, preparación y validación

El archivo de la cátedra contiene 61.913 reservas y 31 columnas (incluidos id y objetivo). El test Kaggle tiene 26.535 reservas sin etiqueta. Esta muestra no coincide con los 119.390 registros del paper original. Se separaron 49.530 filas de desarrollo y 12.383 de validación con estratificación y semilla 42.

Variable faltante	Filas	Tratamiento
children	4	Mediana en fold
country	221	Categoría Sin_dato
agent	7890	Categoría ausencia de agencia/empresa
company	58761	Categoría ausencia de agencia/empresa

Agent/company son códigos categóricos; NULL significa no aplicable según el paper. Se excluye id. Se agregan noches/huéspedes, fechas y día de semana, reserva estimada a partir de anticipación, ADR por huésped, importe aproximado, cambio de habitación y antecedentes. No se utilizan ReservationStatus ni su fecha, que revelarían el resultado y no están en estos archivos.

Los pipelines imputan y codifican dentro de cada fold. KNN normaliza con MinMaxScaler; los árboles no lo necesitan. Se conservaron valores extremos plausibles. En desarrollo se detectaron 56 reservas con cero huéspedes y 236 sin noches; las divisiones por cero generan faltantes para imputación. No se conoce si son errores u operaciones particulares.

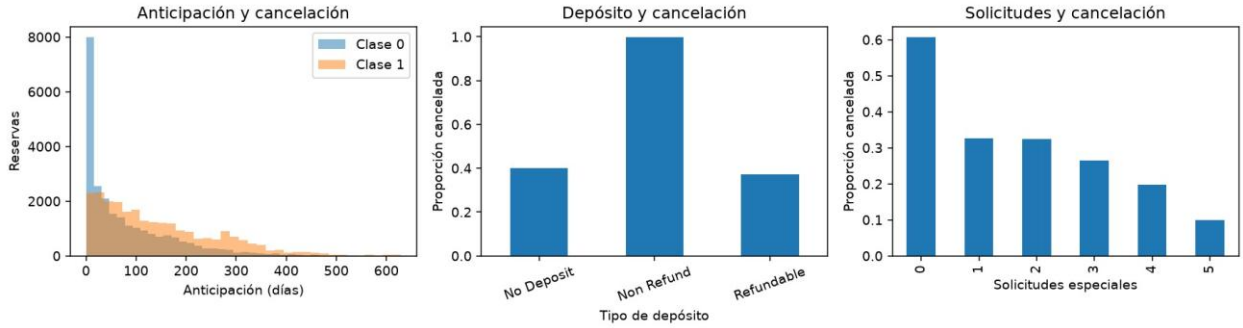


Figura 8. Asociaciones de anticipación, depósito y solicitudes con la cancelación en desarrollo.

Advertencia de evaluación

El 31,92% de validación tiene atributos idénticos a alguna fila de desarrollo. Además, este holdout fue consultado en iteraciones previas. Sirve para comparación histórica, no para afirmar rendimiento independiente. Booking changes, habitación asignada y depósitos pueden reflejar información posterior a reservar: el experimento no demuestra uso al momento de la compra.

EJ3. Modelos e hiperparámetros

Modelo	Cómo funciona / selección	F1 macro CV
Árbol	Reglas sucesivas; profundidad 20, hoja mínima 2	0,85173
Random Forest	600 árboles; profundidad None; max_features=0,25; hoja=1	0,88536
XGBoost	{'learning_rate': 0.06, 'max_depth': 10, 'n_estimators': 1000}	0,88314

Búsqueda GridSearchCV con tres folds estratificados, mismos splits para todos, solo en desarrollo. Árbol: 6 combinaciones; RF: 2; XGBoost: 2. Son búsquedas acotadas de consolidación basadas en las prácticas previas, no una búsqueda exhaustiva. Los CSV guardan todos los candidatos y dispersiones.
El promedio ganador de CV tiene sesgo de selección; no es validación anidada.

Ensambles híbridos

Voting soft: RF + XGBoost + KNN (11 vecinos, peso por distancia); promedio de probabilidades con pesos 2:2:1. El KNN aporta una representación basada en similitud. El ensamble puede ayudar si los errores son distintos; no lo garantiza.

Stacking: mismos tres modelos base; regresión logística C=1 sobre sus probabilidades fuera de fold (3-fold). Luego las bases se reajustan a todo desarrollo. El metamodelo no ve predicciones in-sample para aprender. Sus coeficientes no equivalen a pesos de un promedio y pueden depender de probabilidades correlacionadas.

Coeficientes del metamodelo, orden RF/XGB/KNN: 5,039, 1,169, 1,044. Umbral fijo 0,5 para todos los clasificadores de esta comparación.

Métricas

F1 macro da igual peso a ambas clases y es el criterio principal de la competencia. Precision indica cuántas predicciones de una clase aciertan; recall, cuántos casos de esa clase se recuperan. Accuracy cuenta aciertos globales; ROC AUC evalúa discriminación de probabilidades. No miden costos económicos por sí solas.

EJ3. Comparación de resultados

Modelo / conjunto	F1 macro	Precision macro	Recall macro	Accuracy	AUC
Arbol / train	0,9236	0,9255	0,9237	0,9237	0,9807
Arbol / validacion	0,8508	0,8525	0,8510	0,8510	0,9016
Random Forest / train	0,9965	0,9965	0,9965	0,9965	0,9998
Random Forest / validacion	0,8890	0,8891	0,8890	0,8890	0,9616
XGBoost / train	0,9818	0,9818	0,9818	0,9818	0,9987
XGBoost / validacion	0,8875	0,8875	0,8875	0,8875	0,9596
Voting / train	0,9964	0,9964	0,9964	0,9964	0,9998
Voting / validacion	0,8924	0,8924	0,8924	0,8924	0,9623
Stacking / train	0,9965	0,9965	0,9965	0,9965	0,9998
Stacking / validacion	0,8916	0,8917	0,8916	0,8916	0,9625

El mayor F1 macro en esta validación lo obtuvo **Voting: 0,89243**. La diferencia con entrenamiento debe leerse como sobreajuste, especialmente en modelos complejos. No se puede declarar una mejora del récord público a partir de esta tabla.

Matrices de confusión: validación

Modelo	VN	FP	FN	VP
Arbol	5069	1126	719	5469
Random Forest	5530	665	709	5479
XGBoost	5499	696	697	5491
Voting	5546	649	683	5505
Stacking	5550	645	697	5491

VN: no cancelada correctamente; FP: no cancelada marcada cancelada; FN: cancelada no detectada; VP: cancelada detectada. El notebook presenta también todas las matrices gráficas de train y validación. Los resultados separados por coincidencia exacta están en metricas_solapamiento.csv para transparentar el riesgo de duplicados.

EJ3. Reglas e importancia

Arbol

Principales variables codificadas: cat__deposit_type_Non Refund, cat__market_segment_Online TA, num__lead_time.

```
|--- cat__deposit_type_Non Refund <= 0.50
| |--- num__room_changed <= 0.50
| | |--- num__lead_time <= 11.50
| | | |--- truncated branch of depth 18
| | |--- num__lead_time > 11.50
```

Un corte de una variable continua compara contra un umbral; una dummy con corte 0,5 separa ausencia/presencia de la categoría. Las ramas describen asociaciones predictivas, no acciones que causen cancelación.

Random Forest

Principales variables codificadas: num__lead_time, cat__deposit_type_Non Refund, cat__country_PRT.

```
|--- cat__deposit_type_Non Refund <= 0.50
| |--- cat__market_segment_Online TA <= 0.50
| | |--- num__total_previous_bookings <= 0.50
| | | |--- truncated branch of depth 35
| | |--- num__total_previous_bookings > 0.50
```

Un corte de una variable continua compara contra un umbral; una dummy con corte 0,5 separa ausencia/presencia de la categoría. Las ramas describen asociaciones predictivas, no acciones que causen cancelación.

XGBoost

Principales variables codificadas: cat__deposit_type_Non Refund, num__room_changed, num__required_car_parking_spaces.

La figura del notebook traduce el primer split f235 a su variable codificada. Cada árbol agrega ajustes al logit: una hoja no es una probabilidad de cancelación.

Un corte de una variable continua compara contra un umbral; una dummy con corte 0,5 separa ausencia/presencia de la categoría. Las ramas describen asociaciones predictivas, no acciones que causen cancelación.

Las figuras arbol_Arbol, arbol_Random_Forest y arbol_XGBoost del notebook muestran los primeros niveles. Un árbol del bosque o del boosting no resume el ensamble. Las importancias del árbol/RF miden reducción de impureza; XGBoost usa gain. Variables con más cortes y variables correlacionadas pueden sesgar o repartirse importancia.

Qué aportó y qué no se puede atribuir

Depósito, origen, anticipación y variables operativas aparecen como señales predictivas, según el modelo. En una ablación del árbol con parámetros y folds fijos, las variables originales dieron F1 macro CV 0,84595 y las originales más derivadas 0,85173: diferencia +0,00578. Es evidencia limitada a ese árbol; los parámetros habían sido elegidos con ingeniería. Falta ajustar por separado cada representación y repetir en los ensambles. No se afirma que escalar árboles mejore su rendimiento.

EJ3. Submissions y conclusiones

Se seleccionó el mayor score público de cada método identificado entre 63 registros del historial del equipo: 62 completos con puntaje y un error sin score. No se borraron intentos ni se fusionaron archivos con igual nombre. La red neuronal es un experimento adicional.

Modelo / registro	Test Score local histórico	Public Score Kaggle	Private Score Kaggle
Árbol #57	N/D	0,86244	No disponible
Random Forest #52	0,88815	0,88812	No disponible
XGBoost #31	N/D	0,88742	No disponible
Voting #7	0,89243	0,89307	No disponible
Stacking #20	0,89211	0,89129	No disponible
Red neuronal #1	0,86642	0,86820	No disponible

Fuente: resultados/historicos/envios_competencia.csv, aportado por el equipo; no consulta directa a Kaggle. El número # identifica la fila de ese historial. Test Score es F1 macro de validación histórica con etiquetas, no del test Kaggle ni de la nueva comparación común. Los privados no fueron aportados.

Trazabilidad: #57 es el árbol variante B de Szinvelski; #52, RF semana 2 de Calandria; #31, XGBoost flujo2 ordinal de Sosa (1.600 árboles, tasa 0,025); #7, Voting refinado de Calandria; #20, Stacking _sz de Szinvelski (umbral 0,46); #1, red Keras de Calandria. N/D: no hay evaluación local vinculada con certeza a #57 y #31. No se les asigna la métrica de otro modelo.

Experimentos que no mejoraron

La red sin PCA obtuvo F1 macro CV 0,86210 (con PCA: 0,85739) y público 0,86820, por debajo del Voting. Voting diversidad alcanzó 0,89243 público, sin superar 0,89307. El Voting controlado posterior mantuvo al campeón de control (CV 0,88689) y no exportó otra submission. Añadir complejidad no garantizó progreso.

Conclusión y trabajo futuro

Para esta ejecución local elegiríamos Voting por F1 macro, con las reservas indicadas. En el historial público gana Voting refinado (0,89307). Los JSON antiguos se conservan intactos; el CSV aportado agrega evidencia posterior.

Futuro: validar por grupos y tiempo, comparar ablaciones con folds fijos y medir incertidumbre y costos. Seleccionar repetidamente por leaderboard puede sobreajustar al tramo público; no garantiza el mejor privado.

Anexo. Árboles representativos

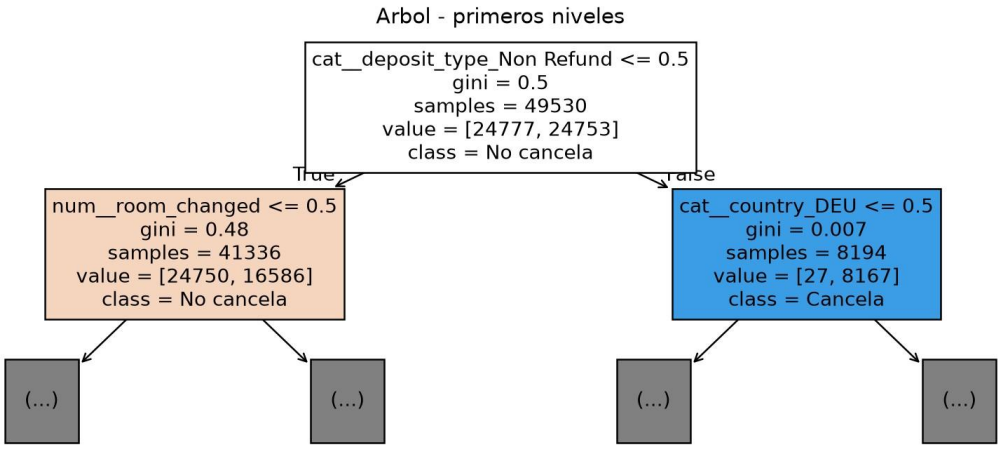


Figura 9. Árbol de decisión: raíz y primeras divisiones; las ramas siguientes se omiten.

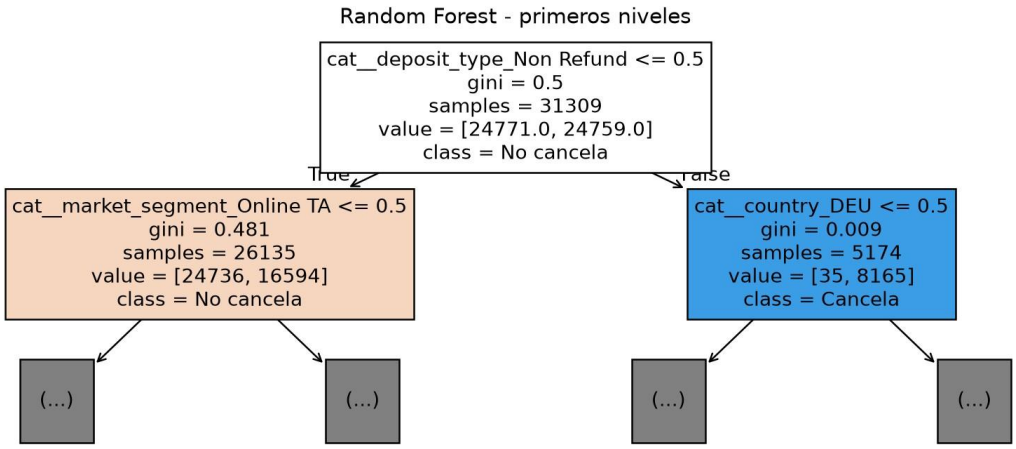


Figura 10. Primer árbol del Random Forest; no representa por sí solo a los 600 árboles.

Los nodos muestran muestras y distribución de clases de entrenamiento. La clase predicha es la mayoritaria del nodo. Para la explicación oral, comenzar en la raíz y seguir una de sus ramas. No interpretar una regla como causalidad.

Anexo. Primer árbol de XGBoost

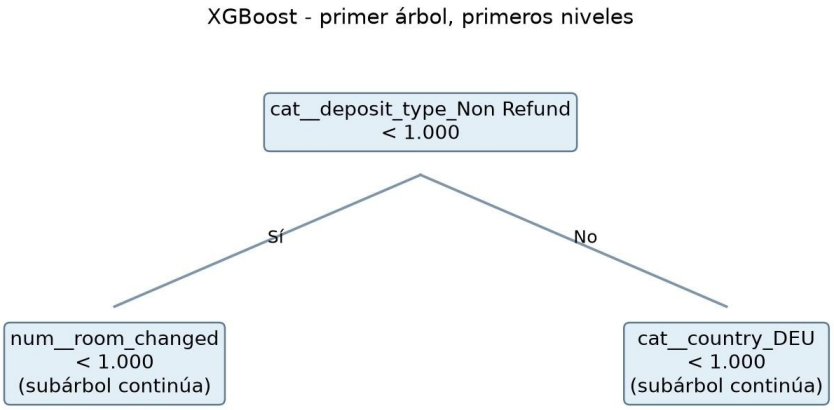


Figura 11. Raíz y divisiones iniciales del primer árbol de boosting. Los subárboles continúan.

XGBoost agrega árboles que corrigen la función de pérdida. El corte divide ejemplos por una variable codificada; las hojas aportan ajustes al logit. La probabilidad final surge de todos los árboles, no del primero. El umbral final 0,5 se aplica a la probabilidad del ensamble, no a una hoja.

Arbol

La primera regla compara cat__deposit_type_Non Refund con 0.500: a la izquierda quedan valores menores o iguales, y a la derecha los mayores. Es una variable One-Hot: un umbral entre 0 y 1 separa ausencia y presencia de esa categoría, no el importe del depósito ni una cantidad.

Random Forest

La primera regla compara cat__deposit_type_Non Refund con 0.500: a la izquierda quedan valores menores o iguales, y a la derecha los mayores. Es una variable One-Hot: un umbral entre 0 y 1 separa ausencia y presencia de esa categoría, no el importe del depósito ni una cantidad. En este árbol, samples cuenta filas distintas del bootstrap y value incorpora sus repeticiones; por eso las cantidades pueden no sumar lo mismo.

XGBoost

La raíz evalúa cat__deposit_type_Non Refund < 1.000. La rama Sí tiene nodeid 1; la rama No, 2. La imputación del pipeline resuelve faltantes antes del árbol. Estas reglas se aplican a variables codificadas, no a etiquetas verdaderas.

Tiempo dedicado

Participación del equipo

La siguiente tabla presenta las tareas y el promedio de horas semanales confirmado por el equipo.

Integrante	Tareas	Promedio de horas semanales
Calandria, Alén Santiago	Coordinación técnica e integración de notebooks; implementación de modelos de hoteles; búsqueda de hiperparámetros y ensambles; preparación de submissions; revisión de reproducibilidad y consolidación de resultados.	8
Szinvelski, Sol Yohara	Coordinación del análisis y del informe; limpieza y preprocesamiento; ingeniería de variables; evaluación de modelos y métricas; interpretación de resultados; integración de conclusiones y preparación de la exposición.	8
Garay Alvarado, Gustavo Alfredo	Apoyo en integración y exploración de datos LEGO; elaboración de gráficos; análisis de preguntas de investigación y perfiles de clusters; revisión de la sección del ejercicio 1.	5
Sosa, Matias	Apoyo en exploración y preparación de Airbnb; comparación de regresión lineal y Random Forest; organización de métricas y gráficos; revisión de la sección del ejercicio 2.	5
Fontanals Layos, Oriol	Documentación de fuentes y decisiones; organización de tablas y figuras; revisión de claridad y formato del informe; preparación del material de exposición y revisión de conclusiones.	5

Dedicación semanal total: **31 horas**. Calandria y Szinvelski: 8 horas cada uno; Garay Alvarado, Sosa y Fontanals Layos: 5 horas cada uno.

Referencias y entrega

Referencias y trazabilidad

1. Rebrickable. Catálogo CSV: https://rebrickable.com/downloads/. Tablas, enlaces exactos, fecha y hashes en fuentes_rebrickable.json.

2. Inside Airbnb. Get the Data, Toronto 16/09/2026: https://insideairbnb.com/get-the-data/. Limitaciones: https://insideairbnb.com/data-assumptions/. Ubicación aproximada; anuncios y calendarios no equivalen a ingresos o demanda realizados.

3. Antonio, N.; de Almeida, A.; Nunes, L. (2019). Hotel booking demand datasets. Data in Brief 22, 41-49. DOI: 10.1016/j.dib.2018.11.126.

4. Notebooks de clase y experimentos semanales del equipo. Los resultados históricos copiados incluyen su archivo deprocedencia y hash. Dependencias de la ejecución: scikit-learn 1.9.0, XGBoost 3.4.1, pandas 3.0.1, NumPy 2.5.3.

Reproducibilidad y entrega

Los tres notebooks se ejecutan desde la carpeta notebooks o desde la raíz del paquete. Las fuentes están incluidas para no depender de futuras actualizaciones web. El módulo src/hotels_features.py acompaña a los modelos serializados. README.md explica instalación, ejecución y verificación.